

修士論文

蛍光テクスチャによる深層学習のための三次元情報を含むデータセット生成手法の提案

指導教員 出村 公成 教授



金沢工業大学
大学院 工学研究科機械工学専攻

岡野昭伍

令和2年度
2021年1月25日

目 次

第1章 序 論	1
1.1 はじめに	1
1.2 本論文の構成	2
第2章 従来研究	3
2.1 アノテーションにおける従来研究	3
2.2 萤光を用いた自動アノテーションにおける従来研究	6
第3章 提案手法	7
3.1 概 要	7
3.2 セマンティックセグメンテーション	11
3.3 萤光マーカテクスチャ	11
3.4 萤光グリッドテクスチャ	11
第4章 実 験	13
4.1 環 境	13
4.2 萤光に対応する実験	14
4.2.1 実験手法	14
4.2.2 実験結果及び考察	15
4.3 セマンティックセグメンテーション	15
4.3.1 実験手法	15
4.3.2 実験結果及び考察	20
4.4 萤光マーカテクスチャの傾きに対する位置姿勢精度	21
4.4.1 実験手法	21
4.4.2 実験結果及び考察	22
4.5 萤光マーカテクスチャの位置精度と紫外線強度の関係	22
4.5.1 実験手法	22

4.5.2 実験結果及び考察	23
4.6 一様なテクスチャとグリッドテクスチャの比較	24
4.6.1 実験手法	24
4.6.2 実験結果及び考察	25
4.7 荧光グリッドテクスチャの精度と紫外線強度の関係	26
4.7.1 実験手法	26
4.7.2 実験結果及び考察	27
4.8 認識の難しい物体への適用	28
4.8.1 実験手法	28
4.8.2 実験結果及び考察	28
第5章 結　言	31
謝　辞	33
参考文献	34
本研究に関する学術発表論文	37

図目次

2.1	Research classification	3
3.1	Overview of proposed method	10
3.2	Point cloud with fluorescent texture	12
4.1	Difference in appearance of fluorescent paint	14
4.2	Environment in visible light source	14
4.3	Difference in line segment width due to uv intensity (N=100)	16
4.4	Green cloth class raw image	18
4.5	Green cloth class ground-truth image	18
4.6	Red cloth class raw image	18
4.7	Red cloth class ground-truth image	18
4.8	Green marker class raw image	19
4.9	Green marker class ground-truth image	19
4.10	Red marker class raw image	19
4.11	Red marker class ground-truth image	19
4.12	Raw image	21
4.13	Predict image	21
4.14	Ground-truth image	21
4.15	Inferred result of semantic segmentation	21
4.16	Marker rotation error (N=100)	23
4.17	Marker position error (N=100)	23
4.18	Different in accuracy due to UV intensity (N=100)	25
4.19	Different in accuracy due to texture (N=100)	26
4.20	Position error due to UV intensity (N=100)	27
4.21	Accuracy of fluorescent grid textures for difficult to recognize objects (N=100)	29
4.22	Metal object under UV light source	29

4.23 Metal object under visible light source	29
4.24 Mirror under UV light source	30
4.25 Mirror under visible light source	30
4.26 Transparent bottle under UV light source	30
4.27 Transparent bottle under visible light source	30
4.28 Transparent bottle with self-occlusion under UV light source	30
4.29 Transparent bottle with self-occlusion under visible light source	30
5.1 Diffrence in appearance of fluorescent paint	32

表 目 次

4.1	Table of difference in line segment width due to UV intensity	15
4.2	Metrics of semantic segmentation	20
4.3	Experiment environment	22
4.4	Experiment environment	24
4.5	Experiment environment	25
4.6	Experiment environment	27
4.7	Experiment environment	28

第1章

序論

1.1 はじめに

近年深層学習を用いた手法が多く提案されている。深層学習に用いられるデータセットを作る際のアノテーション作業は特に時間と手間のかかる作業であり、そのコストの重さが問題となっている [1–6]。そこでこの問題に対して、機械的な処理によってデータセットを生成する自動アノテーションというアプローチが研究されている [7–13]。本研究ではこの分野において、画面上の物体領域といった二次元的な情報や、点群や位置姿勢といった三次元の情報を持つデータセットの自動アノテーションを行うことを目的とする。

自動アノテーションにおいて提案されている手法はいくつかのアプローチに分類できる。それにはシミュレーションを用いるアプローチや [9]、特殊なデバイスや環境を必要とするアプローチ [7,8]、マーカを用いたアプローチ [8,10] などがある。シミュレーションアプローチでは三次元的な情報を扱うことができるが、リアルなデータとシミュレーションのデータの差によるクオリティの問題がある [9,12]。特殊なデバイスや環境を必要とするアプローチには、蛍光塗料を用いたアプローチが属する [7,14]。これらの手法 [7,14] は蛍光塗料の塗布された物体領域のアノテーションを行うことができるが、三次元的な情報を扱うことができない。また、マーカを用いた自動アノテーションのアプローチにはマーカによって対象物体の一部が隠されるマーカオクルージョンといった問題がある。

本研究では、現実のデータを直接扱うためにシミュレーションアプローチと比較してリアルなデータセットを作れる利点がある。加えて、シミュレータで扱うことの難しい不定形の物体に対しても三次元的なアノテーションができる点に有用性がある。蛍光塗料を用いた自動アノテーションでは画面上の物体領域しか扱うことができなかつたが、蛍光塗料によるテクスチャを対象物体に与えるというアプローチによって、従来的な画面上の領域情報に加えて三次元的な位置姿勢及び点群情報についてもアノテーションできるという点

に新規性と有用性がある。さらに、マーカを用いた自動アノテーションのアプローチにはマーカオクルージョン問題があった。これに対しても、可視光下で透明となる蛍光塗料によってマーカを表現することでこの問題を解決している点に新規性と有用性がある。

本研究では、蛍光塗料によるテクスチャを対象物体に与えるというアプローチによって物体の位置姿勢及び点群といった三次元情報やセマンティックセグメンテーションのための領域情報を持った、可視光の環境でも利用可能なデータセットを生成する自動アノテーション手法として蛍光テクスチャを提案する。提案する蛍光テクスチャには与えるテクスチャによってアノテーションするデータを変えることのできる拡張性があり、例えば物体把持タスクのための服の袖や襟といった特定部位の点群、物体中心位置や姿勢、撮影されたシーンのラベル情報などの自動アノテーションを行うことができる。本稿では蛍光テクスチャによる自動アノテーションの例として、ARマーカのテクスチャを与えた蛍光マーカテクスチャとグリッド状のテクスチャを与えた蛍光グリッドテクスチャを提案する。蛍光テクスチャは蛍光塗料の可視光では透明となり紫外線が与えられると可視光を発する性質 [15, 16] を利用しており、可視光下での蛍光テクスチャが透明となりオクルージョンのない画像と紫外線下での蛍光テクスチャの領域が発光している画像を得る。紫外線下での蛍光テクスチャの画像は対応するARマーカの認識手法やステレオ視差、セグメンテーションネットワークなどの既存の認識手法を用いることができ、これによって対象オブジェクトの三次元的な位置姿勢情報や画像上の物体領域が得られる。これらの処理によって可視光下での画像とそのアノテーション情報のペアが得られ、一連の処理を繰り返すことによって可視光下でも利用可能なデータセットを生成する。

1.2 本論文の構成

本論文の構成について述べる。2章では、これまでのアノテーション手法の分類を行い、また自動アノテーション分野における提案手法の立ち位置について述べるとともに関係する従来との違いについて明確にする。3章では、本研究で提案する蛍光テクスチャによる自動アノテーション手法及びその環境について述べる。本研究での新規性と有用性についてもここに明記する。4章では実験環境について述べ、蛍光塗料に対する紫外線強度と光の膨張について評価する。また、セグメンテーションネットワークによって抽出することが可能であることを示すための評価や、提案する蛍光テクスチャの表現の一つとしてARマーカやグリッドを与えた場合の性能評価を行う。加えて蛍光テクスチャを鏡や透明な物体など認識が難しいとされている物体に対して適用した場合についても検証する。5章では本論文の結論をまとめ、今後の展望について述べる。

第2章

従来研究

2.1 アノテーションにおける従来研究

アノテーションとはデータセットに対して正解のラベル付けを行うことであり、ディープラーニングを行うために必要な基本的作業となっている。このアノテーション作業には非常に時間と手間がかかるため、これを容易に行うための様々な方法が考案されている [1–10, 17, 18]。それらの手法は大きく分けて手動アノテーション、半自動アノテーション、自動アノテーションに分類される(図2.1)。

手動アノテーションとは、人間が直接的にアノテーションを行う方法であり、生成する

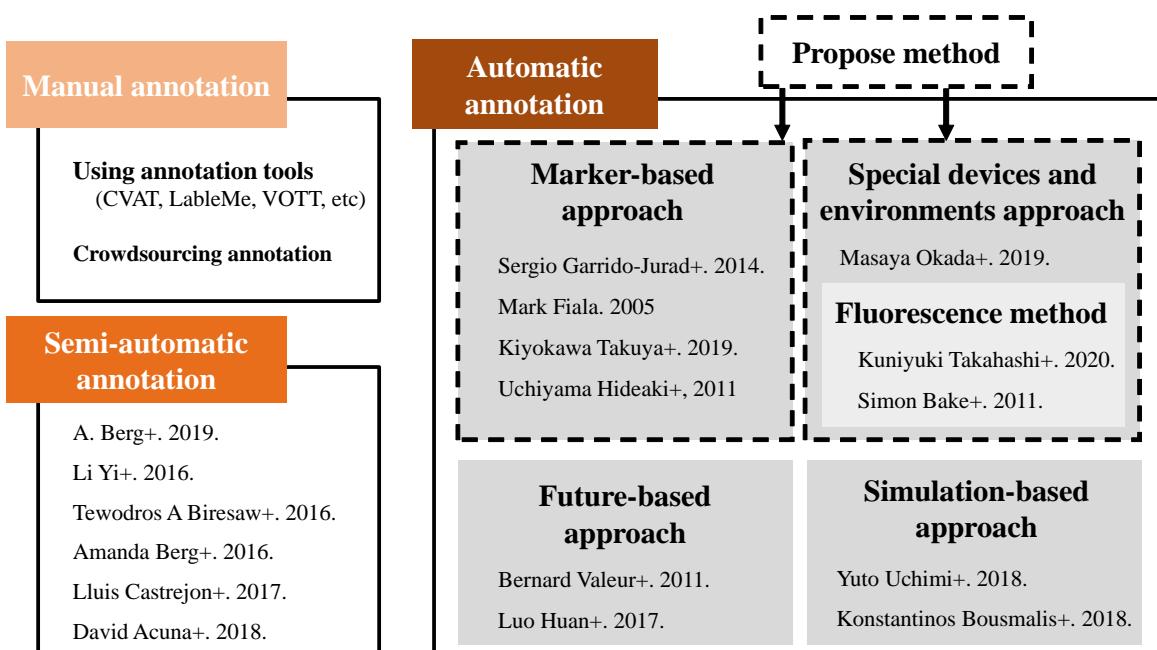


Fig. 2.1: Research classification

データセットのタスクに応じて CVAT、LabelMe、VOTTなどのアノテーションツールを用いて行なうことが一般的である。また、クラウドソーシングなどによって外部のエキスパートではない作業者にアノテーションを代行させる手法もある。

半自動アノテーション手法 [1–6] とは、多くの場合人間と相互作用を行いながらデータセットの生成を行うアノテーション手法のことである [2]。半自動アノテーション手法の例としては、オブジェクトのセグメンテーションタスクにおいて人間が行った少数のアノテーションデータを基に未アノテーションの物体に対してセグメンテーションを行い、その暫定的な出力を人間が手動で修正する方法などがある [1] [2]。またインスタンスセグメンテーションタスクにおいては、人間がトリミングした対象オブジェクトに対して学習済みの特微量抽出器をベースにしたネットワークを用いることでオブジェクトの画像上の輪郭の頂点を生成する手法などがある [5] [6]。これらの手法はどれも人間の操作があることを必要としている。半自動アノテーション手法の多くはビデオ画像に対するオブジェクト検出及びセグメンテーションタスク、動物の行動分類、人間の行動認識、大規模なセグメンテーションタスクなどに対して行われると言われている [1]。

自動アノテーション手法とは [7–10, 12, 13, 15]、機械的な処理によってデータセットを生成する手法である。手動のアノテーションと比べてヒューマンエラーが入らず、データセットをスケールするためのコストが低いという利点がある。自動アノテーション手法はオブジェクトの特徴について注目するアプローチ、マーカアプローチ、シミュレーションアプローチ、特殊なデバイスや環境を用いるアプローチの4つに分類できる [7]。それぞれの手法について以下に述べる。

1. オブジェクトの特徴について注目するアプローチ [13, 15] には、カラートラッキング、サーモグラフィーによる温度でのオブジェクトトラッキングなどがある。これらの手法は対象物体の色 [13] や温度 [15] を特徴として扱っており、例えばシーン内の他の物体が同じ特徴を持っていないことや、時間経過によって物体の特徴が変化しないことなどの前提が必要となる。
2. マーカアプローチ [8, 10, 17–19] では、オブジェクトにARマーカなどの特徴を与える。複数のオブジェクトがある場合でもマーカごとにIDなどを示す可変部分(以降はペイロードと呼ぶ)を変えることで個々のオブジェクトを判別したアノテーションを行うことができる [17–19]。また、多くのARマーカは傾きや大きさから位置や姿勢情報を得ることができるという利点を持っている。しかしマーカは暗い環境など光源環境によっては使用が難しい場合があり、加えてマーカをオブジェクトに貼り付けてアノテーションすると対象オブジェクトの上にあるマーカが対象オブジェクトの一部を隠

してしまうマーカオクルージョンの問題もある。このマーカオクルージョンという問題に対する研究としては、オブジェクトに直接マーカを貼り付けるのではなくマーカによって作られる特殊な台座を用いるものがある [8, 10]。これらの手法 [8, 10] では同一IDのマーカが複数与えられて計測可能となった台座を提案しており、その上に配置された対象オブジェクトの位置姿勢やマーカIDに対応付けられたオブジェクトの種類などをアノテーションする。彼らはマーカ領域にモザイク処理を行ったものをデータセットとして出力して、出力されたデータセットをアテンション機構を持つセグメンテーションネットワークによって学習させることでマーカを注視せずに対象オブジェクト領域を学習できることを示した [8]。

3. シミュレーションアプローチ [9, 12] では、光の当たり方や背景に加えてオブジェクトの位置姿勢や視点の位置などをコントロールしてデータセットを自動的に生成することができる。このアプローチでは不定形な物体のように様々な形が取れるものや水のような流体を扱うことが難しい。またリアルなデータとシミュレーションのデータには差があるために生成するデータセットのクオリティが低くなるという問題もある。これはシミュレーションを用いたデータセット生成の課題となっている [9] [12]。
4. 特殊なデバイスや環境を用いるアプローチ [7, 11, 14] には、コントローラーなどにより検出を行う手法や特殊な環境で光源をコントロールする手法などが分類される。この分類に当てはまるものとしては例えばロボットによって人間の追従を行う研究がある [11]。この研究 [11] では教師データとして進むべき方向を必要としており、ロボットに取り付けられた引き紐を人が持つことでロボットを先導することで紐の力のかかっている方向から正解となる進むべき方向を得ている。また、蛍光塗料などを用いた手法は特殊な環境やデバイスを必要とするためにこの分類に当てはまる。コンピュータビジョンの分野においても蛍光塗料についての研究は行われており [7, 14]、蛍光特性を持つ塗料などの可視光と紫外線をそれぞれ与えたときの見え方の差を利用した方法が提案されている。特に蛍光を扱う研究については2.2節において詳しく述べる。

本研究で提案する手法は上記の分類における第2と第4のアプローチに属する。本研究ではマーカアプローチ固有のマーカオクルージョンの問題に対して、蛍光塗料によってマーカを可視光の下で透明にすることで対応している。

2.2 蛍光を用いた自動アノテーションにおける従来研究

S. Baker ら [14] は、我々が調べた範囲において最初に蛍光を画像処理に適用する研究を行った。彼らの研究はオプティカルフローを利用してオブジェクト追跡を行うものであり、その ground-truth 画像を得るために蛍光塗料を吹き付けるようにして可視光では見えないよううに塗装した対象物体に対して可視光の環境と紫外線の環境を交互に切り替えて撮影することでオプティカルフローのためのデータセットを生成するというものであった。彼らは蛍光を用いて生成したデータセットを用いて提案する手法を評価したが、蛍光によるデータセット生成手法に対する評価は行っていない。

K.Takahashi らの手法 [7] は、あらかじめ蛍光塗料を塗布した対象物体に対して可視光を当てた画像と可視光に加えて紫外線を当てた画像を取得して、それらの画像から得た差分画像に対してセマンティックセグメンテーションを用いることで対象物体の領域を得るというものであった。S.Baker らの手法では可視光のみの環境と紫外線のみの環境を利用したが、K.Takahashi らの手法は可視光のみの環境と可視光に加えて紫外線を与える環境を利用した。K.Takahashi らの手法は紫外線のみの環境ではなくとも蛍光塗料の領域を抽出することが可能であることを示した。

これらの手法 [7, 14] は蛍光を使った自動アノテーションの有用性を示したが、どちらも画面上の情報を得るために注力しており対象物体の三次元的な情報を得ることができない。そこで本研究では、蛍光塗料によって対象物体に計測可能なテクスチャを与えることによって、従来のような画面上の領域情報だけでなく物体の位置姿勢といった三次元的なデータを扱うことを可能にした。本研究は蛍光を画像処理に応用した手法の中で、初めて三次元的な情報を扱うことを可能にした点に新規性がある。さらに、蛍光を用いて三次元的な情報を扱えることを自動アノテーションに応用した点に新規性と有用性がある。

第3章

提案手法

3.1 概要

自動データセット生成に関する手法 [7–10] はいくつか提案されているが限定的な特徴量を扱うだけであった。蛍光を用いてアノテーションを行う手法 [7, 14] もあるがこれらの手法は三次元情報を扱うことができない。

そこで、本研究では対象物体に可視光では透明な蛍光塗料によるテクスチャを与えることによって画面上の情報のみならず三次元的な情報も扱うことを可能にする蛍光テクスチャを提案する。提案する蛍光テクスチャは拡張性のある手法であり、対象物体に与えるテクスチャを変えることで取得する特徴を変えることができる。本稿では蛍光テクスチャを使った例として、AR マーカのテクスチャを与えた蛍光マーカテクスチャとグリッド状のテクスチャを与えた蛍光グリッドテクスチャを提案する。これらのテクスチャは紫外線環境下では対応する AR マーカの認識器やステレオ視差などによって三次元情報を取得することができる。また、セグメンテーションネットワークを用いることでテクスチャの領域抽出も行うことができる。この計測可能なテクスチャを与えることで対象物体の情報も同様に得ることができ、これを利用してデータセットを生成することができる。

蛍光塗料は可視光では透明であるが [15]、紫外線ほどの波長の短い光が与えられるとその光よりも波長が長い可視光のスペクトラムを発するためにカメラで認識することができる [16]。本手法では可視光の光源と紫外線の光源を交互に切り替えながらデータセット生成を行っていく。

本手法における処理の流れを図 3.1 に示す。まず可視光環境で物体を撮影した画像を得る(図 3.1-A)。ここで得た画像は生成するデータセットのために取得され、今後の処理では利用されない。次に、紫外線のみを照射するコントロールされた環境において対象物体を撮影する(図 3.1-B)。ここで得た蛍光テクスチャの画像に 3.3 節 3.4 節 3.5 節で後述する複数の

自動アノテーション手法を適用する(図3.1-C)。これによって可視光環境での画像とそれに対応するオブジェクトの三次元上の位置姿勢や画面上の領域情報を得ることができる。これらの一連の処理(図3.1-A、図3.1-B、図3.1-C)をオブジェクトの配置や環境の設定を変えながら繰り返すことで、可視光下でも利用可能なデータセットを生成する(図3.1-D)。

本手法は不定形の物体にも適用可能である。例えば服の把持位置を教示したい場合は把持の候補となる襟や袖といった部分に対して蛍光テクスチャを用いることで、把持候補の領域情報や三次元的な点群情報を持つデータセットを作ることができる。さらに、従来的な手法では光の反射のために認識が難しいとされている透明物体や鏡、金属板に対しても利用可能である。

本手法の新規性と有用性についてまとめた。

- 対象物体の画像上の情報に加えて、位置姿勢といった三次元情報についても自動的にアノテーションできる点に有用性がある。既存の三次元的な情報を扱うことのできるアプローチとしてはシミュレータを用いたアプローチがある。このアプローチでは対象物体の位置姿勢や光の当たり方などをコントロールしながらデータセットを自動的に生成するが、リアルなデータとの間に差があるという問題がある。本手法では現実のデータを直接扱うため、シミュレータアプローチと比較してリアルなデータセットを作れる利点がある。
- 本研究は蛍光を用いて初めて三次元的な情報を扱うことを可能にした点に新規性がある。また、蛍光を用いて三次元的な情報を扱えることを自動アノテーションに応用した点に新規性と有用性がある。蛍光をコンピュータビジョンの分野に応用した手法としては、蛍光塗料が紫外線に当たると画素値に変化があるということに着目して、画面上の蛍光塗料が塗布されたオブジェクトをトラッキングする手法[14]やセグメンテーションのground-truth画像を得る手法[7]などがあった。これらの手法では画像上の物体領域情報を扱うのみであり物体の三次元的な位置や姿勢を扱うことができない。本研究で提案する手法は蛍光塗料によって対象物体に計測可能なテクスチャを与えることによって三次元のデータを扱えるように拡張されている。
- 本研究ではマーカを用いた自動アノテーションのアプローチ固有の問題を解決している点に新規性と有用性がある。マーカを用いた自動アノテーションのアプローチでは、対象物体に貼り付けられたマーカによって対象物体の一部が隠されるマーカオクルージョン問題があった。本研究ではこのマーカオクルージョン問題に対して、可視光下で透明となる蛍光塗料によってマーカを表現するというアプローチによって解決している。

- シミュレータで扱うことが難しいとされる不定形物体や、カメラやデプスセンサによって認識することの難しいとされる透明物体に対しても適用可能である点に有用性がある。透明なペットボトルや鏡といった物体は光源環境によって大きく見え方が変わることや可視光を透過することのために認識が難しいとされている。本研究で提案する手法では物体表面に等方性のある拡散反射特性を持つ蛍光塗料によってテクスチャを与えるため、どの方向から見ても表面のテクスチャの見え方は等しくなる。

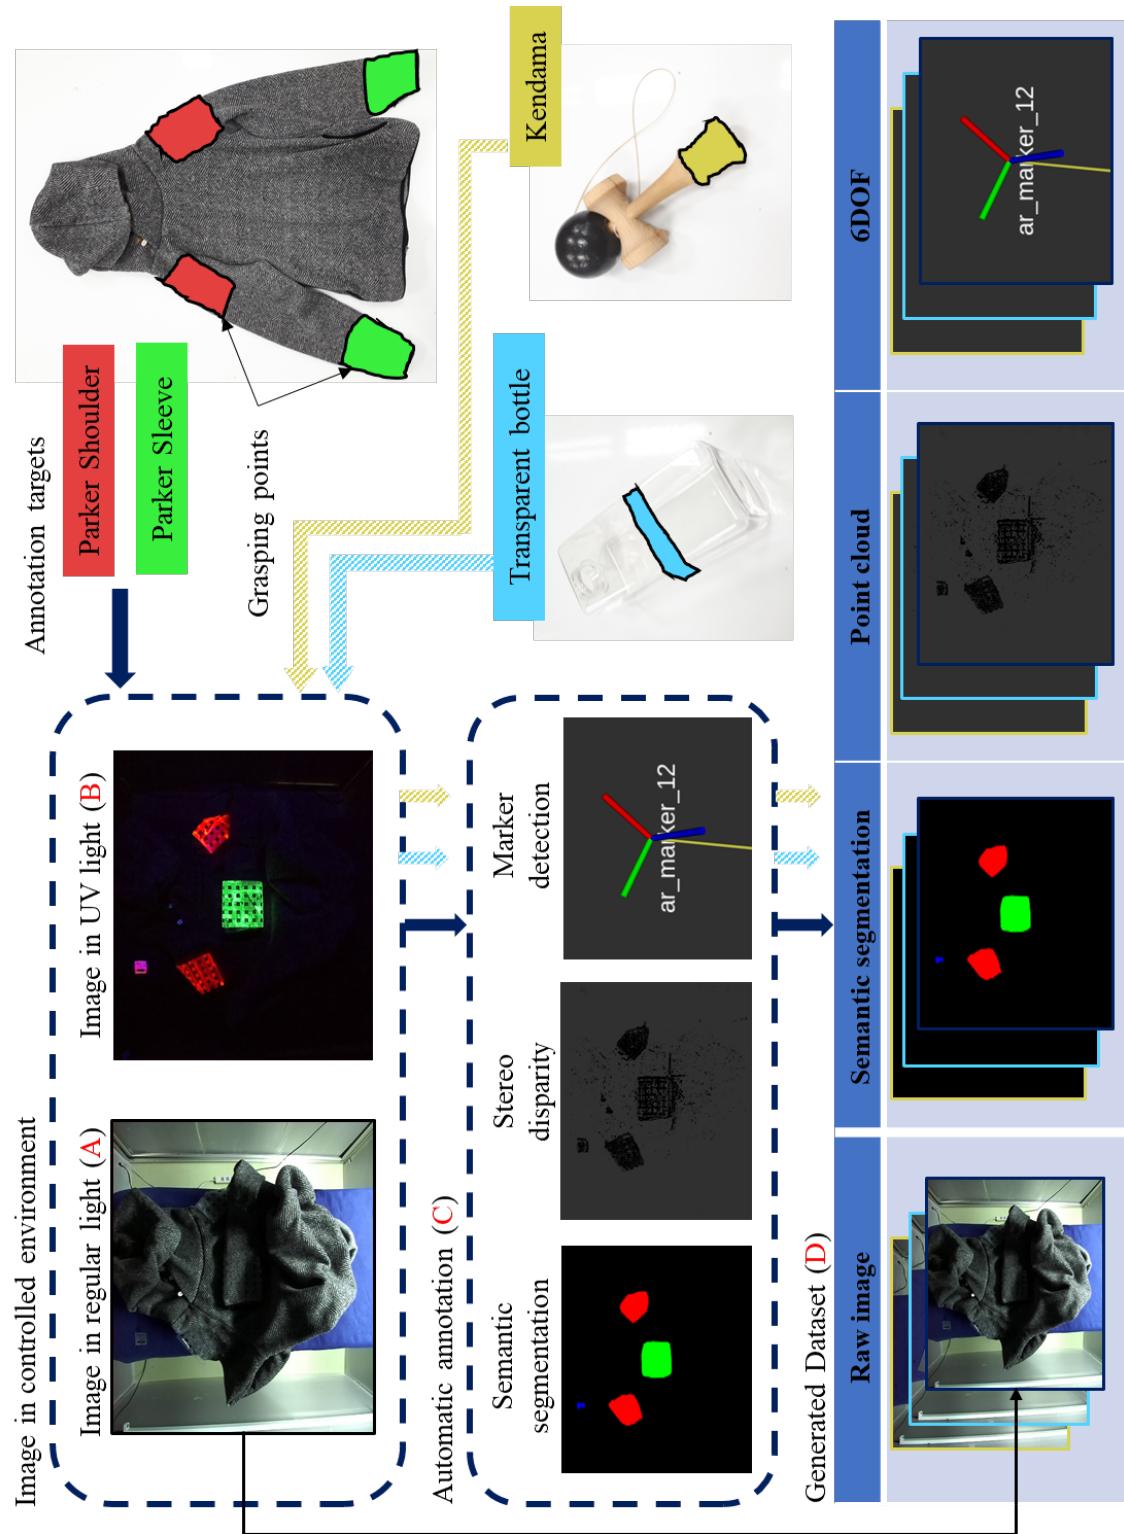


Fig. 3.1: Overview of proposed method

3.2 セマンティックセグメンテーション

本手法では生成するデータセットは一般的なセマンティックセグメンテーションネットワーク [20–22] によって領域情報を得ることができる。ネットワークの入力は紫外線環境下で撮影された画像であり、出力は蛍光テクスチャの領域画像である。また、複数のオブジェクトがある状況においてそれぞれのクラスを判別するために、それぞれのオブジェクトの蛍光テクスチャは異なる色の蛍光塗料が用いられる [7, 14]。

3.3 蛍光マーカテクスチャ

蛍光マーカテクスチャは、一般的な AR マーカ [17, 18] を蛍光塗料によって表現したものである。可視光環境では透明であるが紫外線環境ではマーカ自身が可視光を発するために AR マーカの推定アルゴリズムによって物体表面にあるマーカの三次元位置と姿勢を得ることができる。

多くの AR マーカの認識アルゴリズムはペイロードが白と黒で表現されていることや、ペイロードの外周部分が黒色であることを前提としており [17, 18]、そのままでは様々な色を持つ蛍光塗料によって表現されたマーカを認識することができない。そのため本手法ではカラー画像からそれぞれの色を抽出した画像とそれらを色反転させた画像を入力とする。

蛍光マーカテクスチャの特徴について述べる。蛍光マーカテクスチャは AR マーカの推定アルゴリズムの制限により平面にある必要がある。蛍光マーカテクスチャでは直接的に物体中心の三次元位置を得ることはできないが、任意のマーカ ID にあらかじめ対応付けられた相対位置を指示示すことができる。これにより例えば直接蛍光マーカテクスチャを張ることのできない物体の中心などについても自動アノテーションすることが可能となる。

3.4 蛍光グリッドテクスチャ

蛍光グリッドテクスチャは、可視光環境では透明であるが紫外線環境ではグリッド状に見えるようにテクスチャを与えたものであり、一般的なステレオ視差を用いた手法によって物体表面の三次元点群を得るものである(図3.2)。グリッド状のテクスチャは画像から得られる特徴点を増加させて、ステレオカメラを用いた特徴点対応をとりやすくすることを意図している。この一般的なステレオ視差を用いた方法では、代表的なものではステレオカメラのように水平な複数の視点で得られた画像に対して特徴量抽出を行い、画像間で対応する特徴点同士をマッチングさせる。そして特徴点の移動量を視差として、カメラ間の距

離とカメラの内部パラメータと共にカメラの内部パラメータの式やステレオ視の式に与えることで特徴点ごとの三次元位置を得る。

蛍光グリッドテクスチャは物体表面の点群を得る手法であり姿勢を直接的に得ることはできないが、布のような不定形の物体や曲面を持つ物体に対しても利用できるという特徴がある。

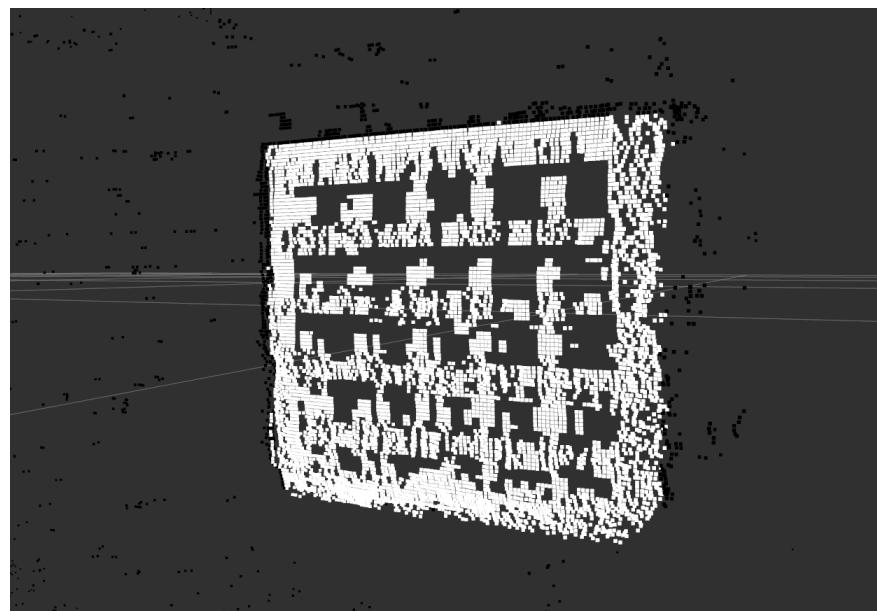


Fig. 3.2: Point cloud with fluorescent texture

第4章

実験

4.1 環境

本手法では外光が入らず、通常の可視光と紫外線を照射できるコントロールされた環境を利用する(図4.2)。蛍光塗料は可視光のみが当たっているときは透明であるが、紫外線が当たると見え方に差が表れる(図4.1)。

可視光と紫外線とは光の波長がそれぞれ $400 \sim 800 [\mu\text{W}/\text{cm}^2]$ 、 $200 \sim 400 [\mu\text{W}/\text{cm}^2]$ の光のこととして扱う[16]。本手法で用いる環境では紫外線を照射する際に1 [lux]以下の可視光も照射されるが、便宜上本手法ではその場合も紫外線のみの環境であると表記する。不可視の紫外線が照射された際に与えられた光エネルギーを受け取り、波長を下げた光として放出する特性のことを蛍光特性という[15]。蛍光塗料はこの蛍光特性を持った物質によって作られている。蛍光の物体から発される光の中で $200 \sim 400 [\mu\text{W}/\text{cm}^2]$ まで波長が下がったものが人間やカメラに可視光としてとらえることができる。

次に紫外線照射機と紫外線強度器について述べる。紫外線を計測する機器はメーカーごとに波長への反応特性が異なる。この紫外線計測器の特性上の問題により紫外線の照射量を計測することは非常に困難とされている[16]。本稿においては紫外線に対する指標として計測器に表示される紫外線強度をそのまま用いることとする。紫外線の照射機は東芝4形ブラックライト直管蛍光灯を用いて、紫外線強度の計測器は竹村電気DX-100を用いる。



Under regular light

Under UV light

Fig. 4.1: Difference in appearance of fluorescent paint



Fig. 4.2: Environment in visible light source

4.2 蛍光に対応する実験

4.2.1 実験手法

蛍光塗料は紫外線強度の強弱によってはほとんど見えなくなる場合や光が強すぎて実際よりも物体が膨張して見えることがある。そのため、本実験では紫外線強度を変化させた際の蛍光物体の見え方について調査することで、蛍光塗料が認識できなくなる場合や光の膨張が起こる場合の条件を調べる。

本実験では蛍光物体に対して紫外線強度のみを変えることで紫外線強度と蛍光塗料の見え方の変化を調査する。この蛍光物体の形状は基本的なものとして線分を採用して、蛍光物体の見え方の差を線分の幅として計測する。また、参考として比較するために蛍光の線分と同じサイズの可視光で不透明な線分について可視光環境(400[lux])と紫外線を照射する

Table 4.1: Table of difference in line segment width due to UV intensity

線分のサイズ	5×300 [mm]
カメラと線分の距離	700 [mm]
紫外線強度計	竹村電気 DX-100
紫外線強度	139 [$\mu\text{W}/\text{cm}^2$]
可視光	400 [lux]

ときの見え方の差についても比較する。用意する可視光で不透明な線分は一般的な印刷用紙を使用して、蛍光線分と同じ大きさにするためにレーザーカッターによって切り出す。線分の幅については画像ごとに中央値を取り、取得した画像 100 フレーム分についての線分の幅を実験結果として得る。なお、紫外線環境下での光の膨張の発生とは、物体が可視光下での見え方よりも 2 ピクセル以上大きく見えることとして扱う。実験環境及び蛍光物体の形状については表 4.1 に示す。

4.2.2 実験結果及び考察

本節では 4.2.1 小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。実験の結果を図 4.3 に示す。実験結果から、紫外線強度が 200 [$\mu\text{W}/\text{cm}^2$] 以上になると光の膨張が顕著になることが示された。また、紫外線強度が最小の場合 15 [$\mu\text{W}/\text{cm}^2$] と比べて最大の場合 470 [$\mu\text{W}/\text{cm}^2$] では線分の幅が 2 倍近くになるという差が表れた。また可視光の環境において同一形状の線分の幅が 5 ピクセルとなることから、誤差 1 ピクセル以内が同じ見え方であるとした場合において、実験環境の設定では少なくとも紫外線強度 $50 \sim 200$ [$\mu\text{W}/\text{cm}^2$] の範囲で通常の可視光源を用いたときと同じ見え方となることが示された。

4.3 セマンティックセグメンテーション

4.3.1 実験手法

3.3 節では、提案する複数の蛍光テクスチャの領域を抽出する手法を提案した。似たタスクに取り組んでいる研究があるが [7]、提案する手法は従来の蛍光塗料の領域をセグメンテーションする研究と比較して扱うテクスチャのバリエーションが豊富である点が異なる。このことから、本手法で扱うセグメンテーションタスクは従来研究で検証されたタスクとは異なるものになっている。

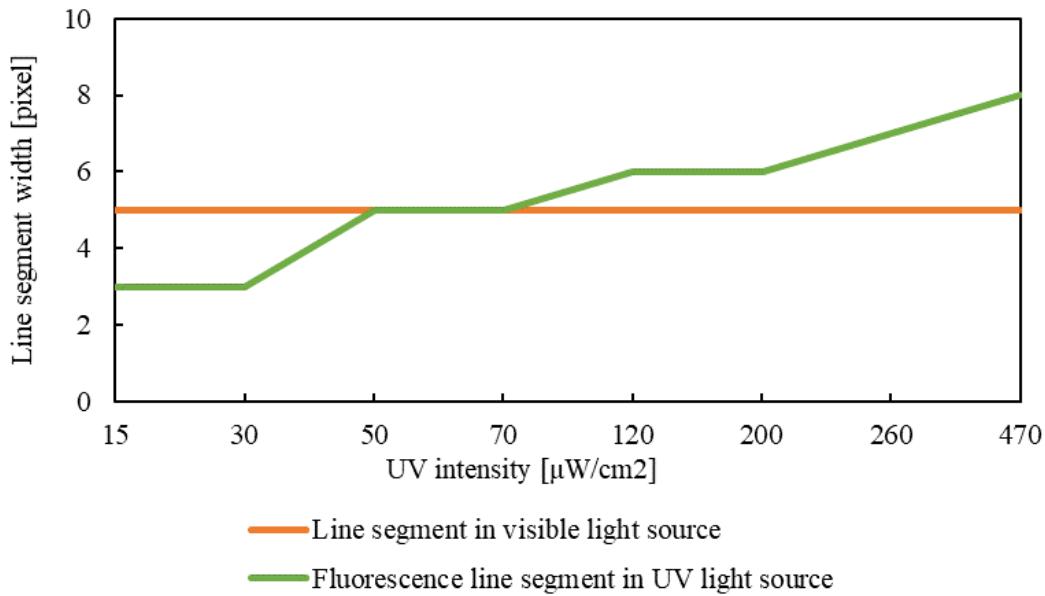


Fig. 4.3: Difference in line segment width due to uv intensity (N=100)

そのため、本実験ではこの蛍光テクスチャのセマンティックセグメンテーションという新しいタスクに対して、ディープラーニング手法を用いて蛍光塗料の領域を抽出することができるのかどうかについてテストすることを目的とする。その方法としては、提案する蛍光テクスチャに対して典型的なセマンティックセグメンテーションネットワークである U-Net [20]、FPN [21]、LinkNet [22] に学習させた結果を評価する。

続いてハイパーパラメータや学習時の設定について述べる。事前のパラメータサーチの結果から、エンコーダ層は imangenet によって事前に学習された ResNet [23] を用いて fine-tuning することとして、ClassWeight は背景ではないクラスと背景クラスが 2 対 1 とする。また EarlyStopping の条件は学習する各エポックごとの検証用のデータセットに対する IOU 及び F1 Score の精度が直近 6 エポックのデータと比較して向上していないこととする。さらにネットワークの損失関数については Dice Loss と Focal Loss を掛け合わせた DiceFocalLoss [24] を用いる。Dice Loss は面積の一致率に影響して類似度を計測する損失関数であり、Focal Loss は Cross entropy loss の損失を動的に変える損失関数である。Focal Loss はクラス確率が高く簡単に分類に成功したデータの損失を小さくすることで簡単に分類できるデータの寄与度を小さくし、クラス確率が低くより分類が難しいデータに対してはデータの寄与度を大きくするように作用する。

実験に利用するデータセットとして、提案する蛍光マーカテクスチャと蛍光グリッドテクスチャを赤と緑で表現した計 4 クラスの画像を合計 1103 枚利用する。また、利用するデータセットが少量であることから、検証の正当性を高めるために 5 分割の交差検証を行う。な

お、5分割の学習における内訳はTrain:Test:Validation=3:1:1とする。

適用するデータ拡張手法について述べる。学習する画像を一定の確率によってそれぞれのデータ拡張手法を適応するかどうかランダムに決定する。そのため1枚の画像に対して複数のデータ拡張手法が適用される場合もある。なお、このデータ拡張によって学習に用いるデータの枚数は変化しない。また、画像をぼかすように変換するデータ拡張手法はいくつもあるが、そのような似た作用をする拡張手法をすべて適用したならばそのデータ拡張によって生まれた画像間のバリアンスは小さくなる。これを避けるため、ぼかしのデータ拡張を行う際は複数のぼかし手法の中から一様な確率でランダムに1つの手法を選び適用することにする。また、明るさを変換する手法やコントラストを変換する手法に対しても同様に扱う。ランダムなデータ拡張を行った画像を図4.4 図4.5 図4.6 図4.7 図4.8 図4.9 図4.10 図4.11に示す。これらの画像は以下に列挙するデータ拡張手法を確率的に適用したものである。

- Flip ($p=0.5$)
- Affine transformation ($p=1$)
- Gaussian noise ($p=0.2$)
- Contrast group ($p=0.9$)
 - Contrast Limited Adaptive Histogram Equalization
 - Brightness
 - Gamma
- Blur group ($p=0.9$)
 - Sharpen
 - Blur
 - Motion blur
- Brightness conversion group ($p=0.9$)
 - Contrast transformation
 - Hue station value transformation

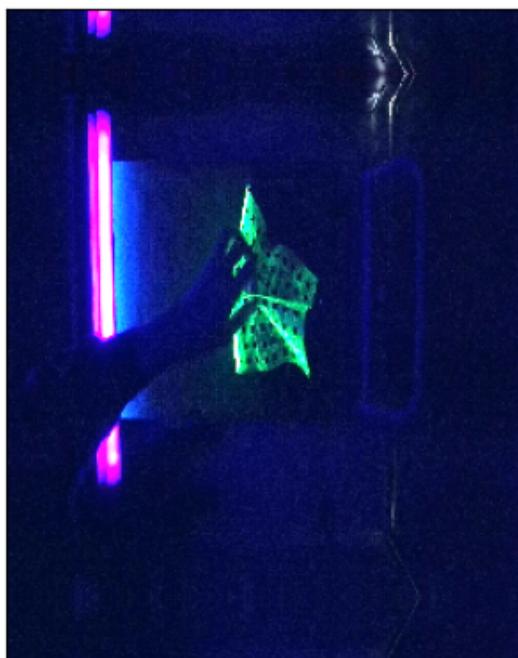


Fig. 4.4: Green cloth class raw image

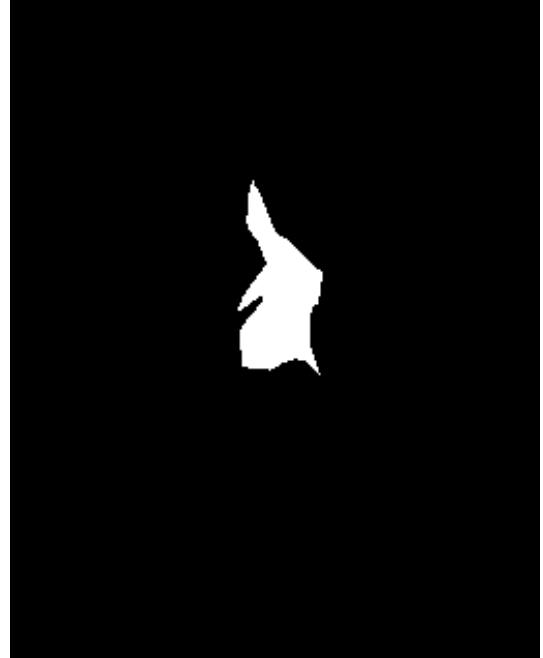


Fig. 4.5: Green cloth class ground-truth image

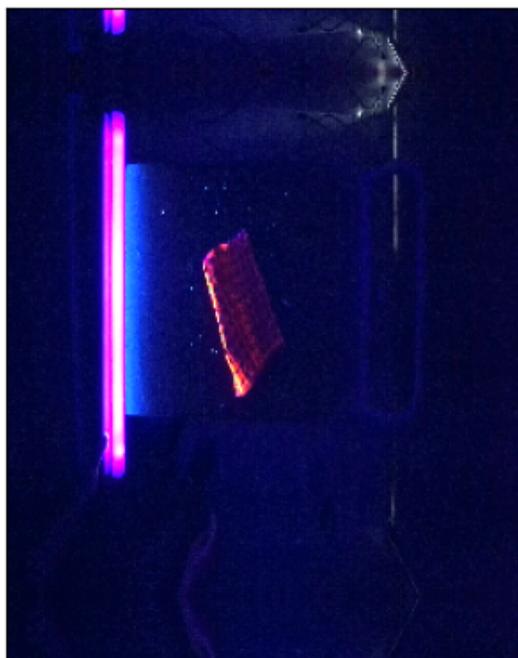


Fig. 4.6: Red cloth class raw image

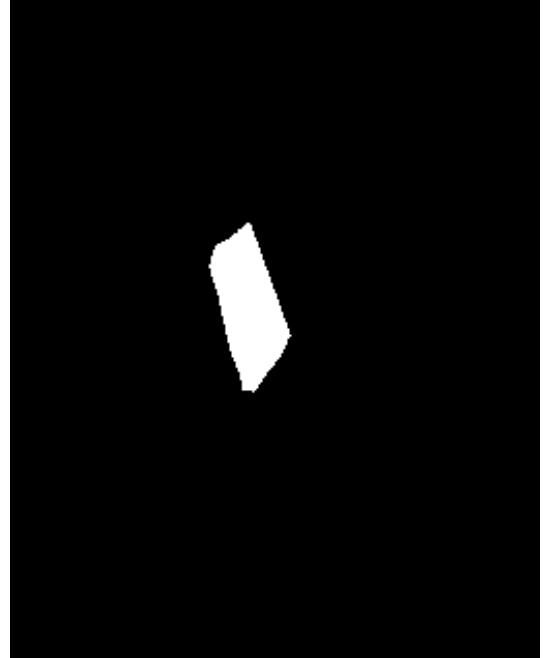


Fig. 4.7: Red cloth class ground-truth image

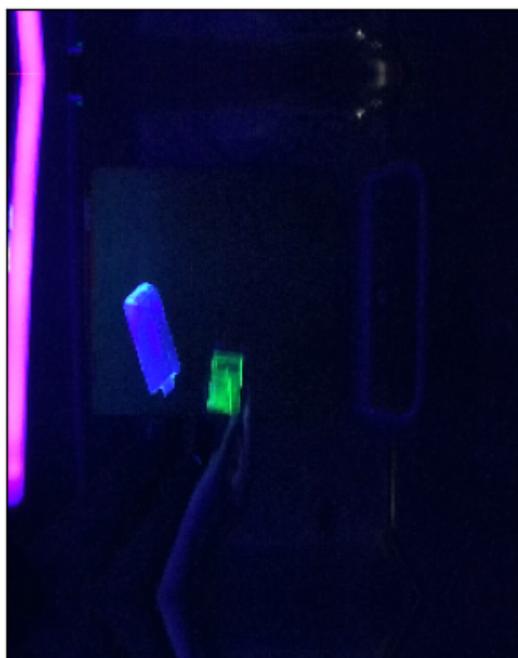


Fig. 4.8: Green marker class raw image

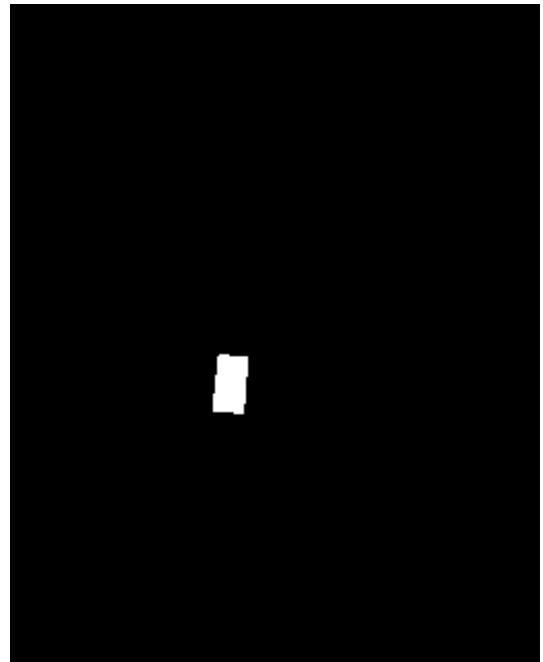


Fig. 4.9: Green marker class ground-truth image

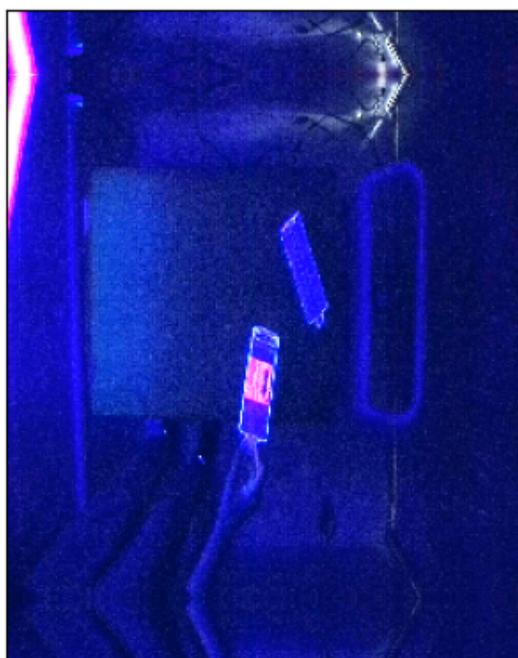


Fig. 4.10: Red marker class raw image

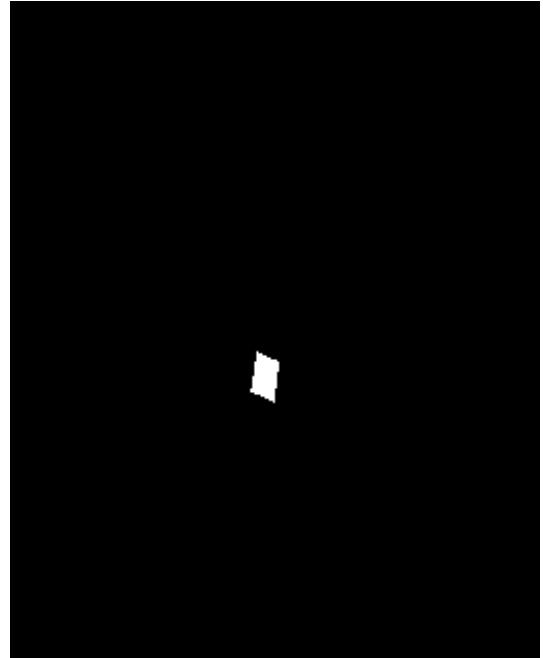


Fig. 4.11: Red marker class ground-truth image

4.3.2 実験結果及び考察

本節では、4.3.1小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。

表4.2に複数のネットワークに対する交差検証の結果を示す。実験の結果、IOUとF1 ScoreはそれぞれUnetにおいては0.862、0.872となり、Linknetにおいては0.877、0.893となり、またFPNにおいては0.862、0.878となった。この中で最も良好なスコアを示したのはLinknetであった。Linknetによって学習に使っていない画像を推論した際の入出力画像及び正解の画像を図4.12、図4.13、図4.14に示す。正解画像では指の間から見える蛍光領域はアノテーションされていないが、推論画像では指の間から見える部分についてもアノテーションされている。

また、服や道具といった物体把持の自動アノテーションを行うシチュエーションを想定して、最も良好な結果を示したLinknetで学習に用いていないデータに対して推論した結果を図4.15に示す。図4.15では服の襟と袖、懐中電灯とけん玉の取っ手部分、透明容器の中央部分に蛍光グリッドテクスチャを与え、磨かれたアルミ板の表面を蛍光マーカテクスチャによってアノテーションしている。図4.15の3列目において少なくとも一般的な蛍光物体の一つであるプラスチックの持つ蛍光に対してネットワークは反応していないことが示されている。

Table 4.2: Metrics of semantic segmentation

	Unet	Linknet	FPN
IOU	0.862	0.877	0.862
F1-score	0.872	0.893	0.878

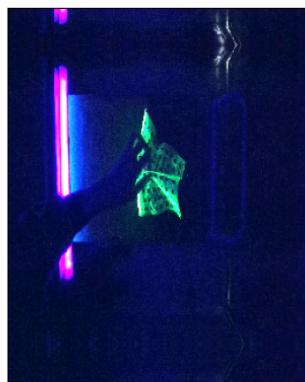


Fig. 4.12: Raw image



Fig. 4.13: Predict image



Fig. 4.14: Ground-truth image

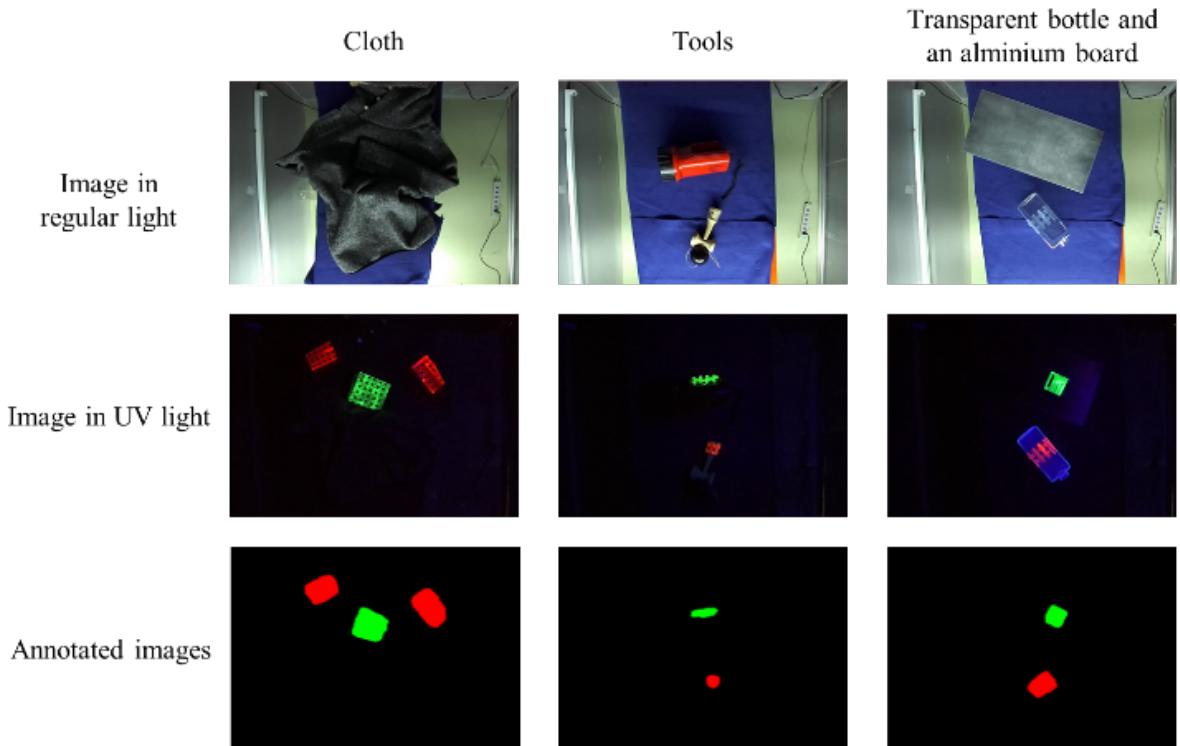


Fig. 4.15: Inferred result of semantic segmentation

4.4 荧光マーカテクスチャの傾きに対する位置姿勢精度

4.4.1 実験手法

本研究では蛍光塗料によって AR マーカのテクスチャを物体に与えることで、従来の手法で問題となっていた AR マーカの映り込みの問題を回避しつつ対象物体の三次元位置と姿勢

Table 4.3: Experiment environment

ARMarker	ArUcoMarker
ARMarkerSize	56 [mm]
カメラとマーカの距離	470 ~ 600 [mm]
紫外線強度計	竹村電気 DX-100
紫外線強度	120 ~ 240 [$\mu\text{W}/\text{cm}^2$]

を得ることを可能とする蛍光マーカテクスチャを提案した。本実験では、インクで印刷された白黒の通常マーカと蛍光塗料によって作られた蛍光マーカに関して、姿勢の精度について比較することを目的とする。

実験方法について述べる。通常マーカと蛍光マーカを同一平面上に配置する。この2つのマーカに対して Roll/Pitch 方向に変化を与え、その時のそれぞれのマーカに対して可視光と紫外線をそれぞれ与えて姿勢の推定値を計測する。なお、実験環境については表4.3に示す。

4.4.2 実験結果及び考察

本節では、4.4.1小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。

蛍光マーカテクスチャに対して Roll/Pitch 方向に姿勢を変化させた際の姿勢の誤差を図4.16に示し、位置の誤差を図4.17に示す。位置と姿勢のどちらも蛍光マーカテクスチャの誤差が大きい場合や通常のマーカの誤差が大きい場合があった。どちらのマーカについてもマーカの角度が 10 ~ 20[degree] の範囲にでは比較的誤差が大きい結果となったが、これは傾きが小さい場合はマーカが順方向と逆方向のどちらに対して傾いているかを確認することが視覚的に困難であるためであると考える。

4.5 蛍光マーカテクスチャの位置精度と紫外線強度の関係

4.5.1 実験手法

本研究では蛍光塗料によって AR マーカのテクスチャを物体に与えることで、可視光では不可視だが紫外線環境は可視となるテクスチャを提案した。

本実験では、白黒の通常マーカと蛍光塗料によって作られた蛍光マーカに関して、姿勢の精度について比較することを目的とする。方法としては黒色のインクで印刷された通常

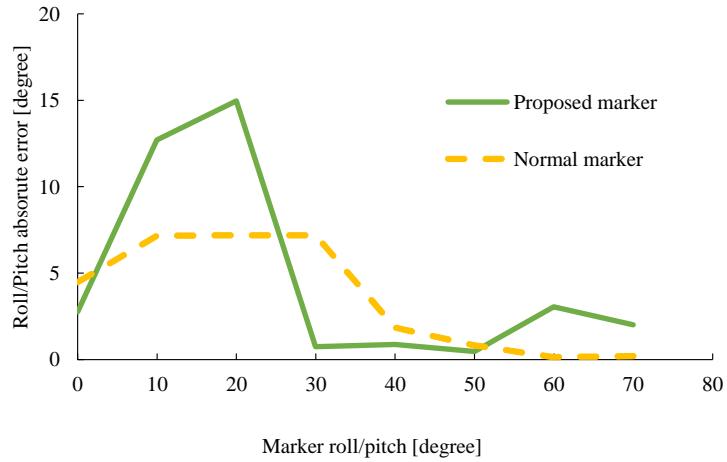


Fig. 4.16: Marker rotation error (N=100)

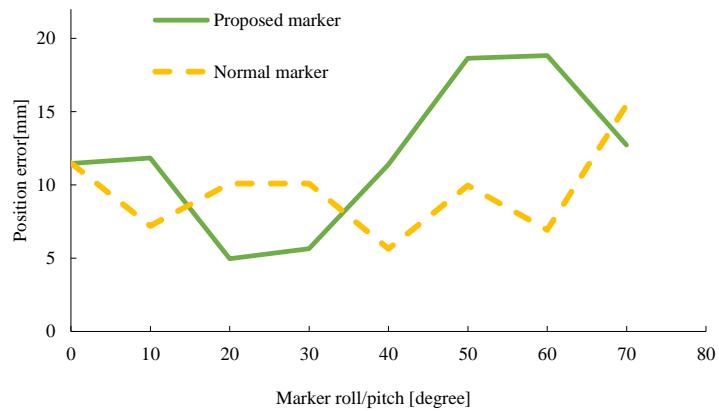


Fig. 4.17: Marker position error (N=100)

の AR マーカと蛍光マーカテクスチャを同一平面上に配置する。そして蛍光マーカテクスチャに対して紫外線強度を変化させた際の位置精度と、通常の AR マーカを可視光環境(400 [lux])で計測した際の精度を比較する。なお、実験環境の設定については表 4.4 に示す。

4.5.2 実験結果及び考察

本節では、4.5.1 小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。

蛍光マーカテクスチャの位置精度と紫外線強度の関係性を図 4.18 に示す。実験によって紫外線強度 40 ~ 140 [$\mu\text{W}/\text{cm}^2$] では可視光環境での通常のマーカと同じ精度となった。40

Table 4.4: Experiment environment

ARMarker	ArUcoMarker
ARMarkerSize	56 [mm]
カメラとマーカの距離	570 [mm]
紫外線強度計	竹村電気 DX-100
紫外線強度	40 ~ 260 [$\mu\text{W}/\text{cm}^2$]

~140 [$\mu\text{W}/\text{cm}^2$]における蛍光マーカテクスチャの位置精度は6.4 [mm]であり、深度方向の精度は3.5 [mm]であった。また、紫外線強度160 [$\mu\text{W}/\text{cm}^2$]以上で誤差が大きくなり、紫外線強度200 [$\mu\text{W}/\text{cm}^2$]以上で認識されない結果となった。

紫外線強度200 [$\mu\text{W}/\text{cm}^2$]以上でARマーカが認識されなくなった理由について考察する。ArUcoマーカはマーカの候補領域をN×Nのグリッドとして区切り、それぞれのグリッドに対して白要素と黒要素のピクセル数の投票によってペイロードの値を決めている[17, 18]。紫外線強度が一定よりも大きくなつた場合に光の膨張が起つり、マーカのペイロードが正しく読み取れなくなつてゐるために認識がされなくなつたと考えられる。また、紫外線強度160 [$\mu\text{W}/\text{cm}^2$]を超えた際に誤差が大きくなる理由としては、蛍光マーカテクスチャで使用したArUcoMarkerは三次元位置推定にマーカの輪郭位置の線形回帰を用いており[17]、光の膨張によつて変化するマーカの輪郭に影響されているためであると考えられる。その場合、ARマーカの手法の多くが線形回帰によつて距離を求めてゐることから[17, 18]、この結果は蛍光マーカテクスチャで表現するマーカが他のARマーカであったとしても同様の結果になる。

4.6 一様なテクスチャとグリッドテクスチャの比較

4.6.1 実験手法

本研究では蛍光塗料によつて対象物体へテクスチャを与えることで従来手法のように画面上の情報を扱うだけではなく三次元的な情報も扱う事のできる蛍光テクスチャを提案した。また提案した蛍光テクスチャを用いてグリッド状のテクスチャを与えることで、ステレオ視差によつて画像間の特徴点の対応付けが可能となる蛍光グリッドテクスチャを提案した。

本実験では、蛍光グリッドテクスチャが従来的な一様に対象物体に蛍光塗料を塗つたテクスチャよりも有用性があることを示すため、蛍光グリッドテクスチャと蛍光塗料を一様に塗布した二つのテクスチャからそれぞれステレオ視によつて得られる点群の深度情報に対

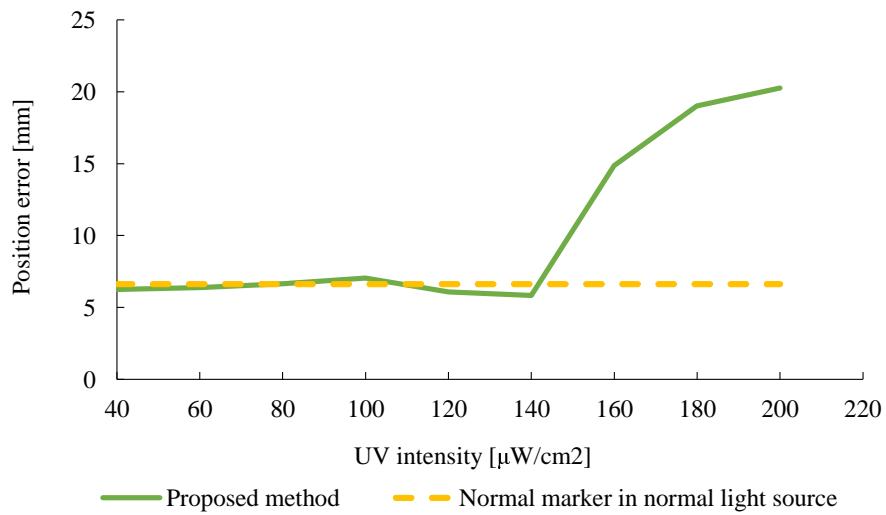
Fig. 4.18: Different in accuracy due to UV intensity ($N=100$)

Table 4.5: Experiment environment

ステレオカメラ	ZED2
グリッド幅	10 [mm]
カメラとマーカの距離	570 [mm]
紫外線強度計	竹村電気 DX-100
紫外線強度	102 [$\mu\text{W}/\text{cm}^2$]

する三次元位置精度を評価する。実験方法としては、蛍光グリッドテクスチャと一応な蛍光テクスチャを同一平面上に配置してデータを取得する。実験環境の条件を表 4.5 に示す。なお、ステレオ視によって点群を得るためのツールとして StereoLabs 社の zed-ros-wrapper¹ を用いる。

4.6.2 実験結果及び考察

本節では、4.6.1 小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。

位置精度についての実験結果を図 4.19 に示す。提案する蛍光グリッドテクスチャと一様なテクスチャから得られた点群の精度に関して述べる。どちらも誤差の中央値はほぼ同じであったが、提案する蛍光グリッドテクスチャの方が分散は小さく、かつ誤差の第三四分位

¹<https://github.com/stereolabs/zed-ros-wrapper>

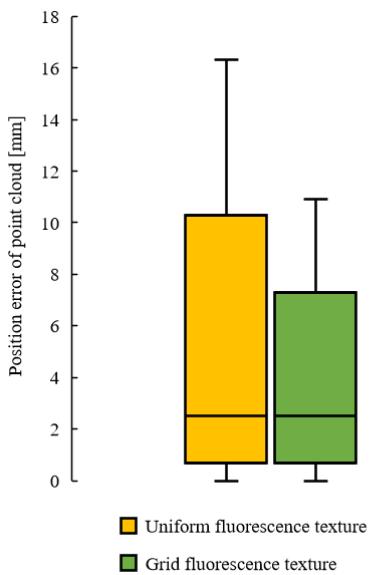


Fig. 4.19: Different in accuracy due to texture (N=100)

数が小さくなっているという結果となった。このことから、蛍光グリッドテクスチャから得られた点群は一様なテクスチャから得られた点群よりも良好な精度であると言える。

4.7 蛍光グリッドテクスチャの精度と紫外線強度の関係

4.7.1 実験手法

本研究では蛍光塗料によって対象物体へテクスチャを与えることで画面上の情報だけではなく三次元的な情報も扱う事のできる蛍光テクスチャを提案した。また蛍光テクスチャを利用したもの一つとして、ステレオカメラによってテクスチャ表面の点群情報を得る蛍光グリッドテクスチャを提案した。しかし可視光下で用いられる多くの画像認識手法が光の強弱に影響されるように、この蛍光グリッドテクスチャもまた紫外線の強弱によって認識精度に影響を受けることが考えられる。

本実験では、提案する蛍光グリッドテクスチャの有用性について検証することを目的として、紫外線強度を変化させたときの点群の深度に対する位置精度を計測する。実験環境について表4.6に示す。ステレオ視で点群を得るためにツールとして4.5節と同様に zed-ros-wrapper を用いて、真の値は環境から計測する。

Table 4.6: Experiment environment

ステレオカメラ	ZED2
グリッド幅	10 [mm]
カメラとマーカの距離	570 [mm]
紫外線強度計	竹村電気 DX-100

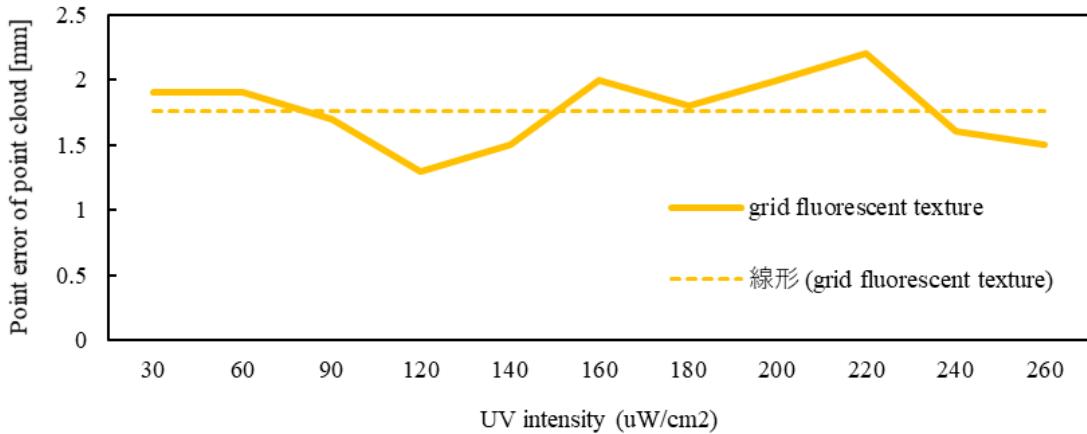


Fig. 4.20: Position error due to UV intensity (N=100)

4.7.2 実験結果及び考察

本節では小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。

紫外線強度を変化させたときの点群の深度方向の精度について、実験で得られたデータと誤差の中央値を最小二乗法によって線形近似した直線をプロットしたものを図 4.20 に示す。近似直線の傾きから、少なくとも実験した紫外線強度の範囲において、提案手法で得られた点群の精度は紫外線強度に影響されないことが明らかになった。また計測した各紫外線強度における誤差の平均は 1.8 [mm] であり、これは光の膨張が起きていないときの蛍光マーカテクスチャの深さへの誤差 3.5 [mm] よりも小さい値となっている。

Table 4.7: Experiment environment

ステレオカメラ	ZED2
グリッド幅	10 [mm]
カメラとマーカの距離	570 [mm]
紫外線強度計	竹村電気 DX-100
紫外線強度	100 ~ 106 [$\mu\text{W}/\text{cm}^2$]

4.8 認識の難しい物体への適用

4.8.1 実験手法

本研究では蛍光塗料によってグリッド状のテクスチャを与えることで、物体表面の三次元点群を推定できる蛍光グリッドテクスチャを提案した。

本実験では、鏡、透明な容器、金属板といった認識が難しいとされている物体に対して提案する蛍光テクスチャを適用できるのかどうかについて確認することを目的とする。そのため、光の関係で認識の難しいとされる上記の物体と一般的な非蛍光の物体として市販されている布にそれぞれ蛍光グリッドテクスチャを与え、得られた点群の位置精度について評価を行う。なお、透明な容器は光の透過があるために蛍光グリッドテクスチャを一つの面にのみ与えてセルフオクルージョンが発生する場合と発生しない場合の2通りを検証する。実験環境の設定について表4.7に示す。

4.8.2 実験結果及び考察

本節では4.8.1小節で述べた方法で実験を行った結果についてまとめ、その内容について考察する。

特殊な物体に対して蛍光グリッドテクスチャを用いて推論された点群の真の値との誤差を図4.21に示す。照明環境に大きく影響されないものとして計測したマットとの誤差の差は、金属は0.24 [mm]、オクルージョンなしの透明容器は0.38 [mm]、オクルージョンありの透明容器は0.43 [mm]であった。

透明容器に対してはオクルージョンの有無による精度の差は0.05 [mm]であり、セルフオクルージョンは精度に関わらないという結果になった。

また、実験では鏡に対する点群の誤差が他の物体と比較して大きくなるという結果が得られた。この理由としては、カメラが板ガラスの表面にあるテクスチャではなく、鏡のメッ

キ部分で反射した蛍光テクスチャを認識しているからだと考えられる。ガラス部分の厚みを考慮することで本手法によって鏡を扱うことは可能となると考えられる。

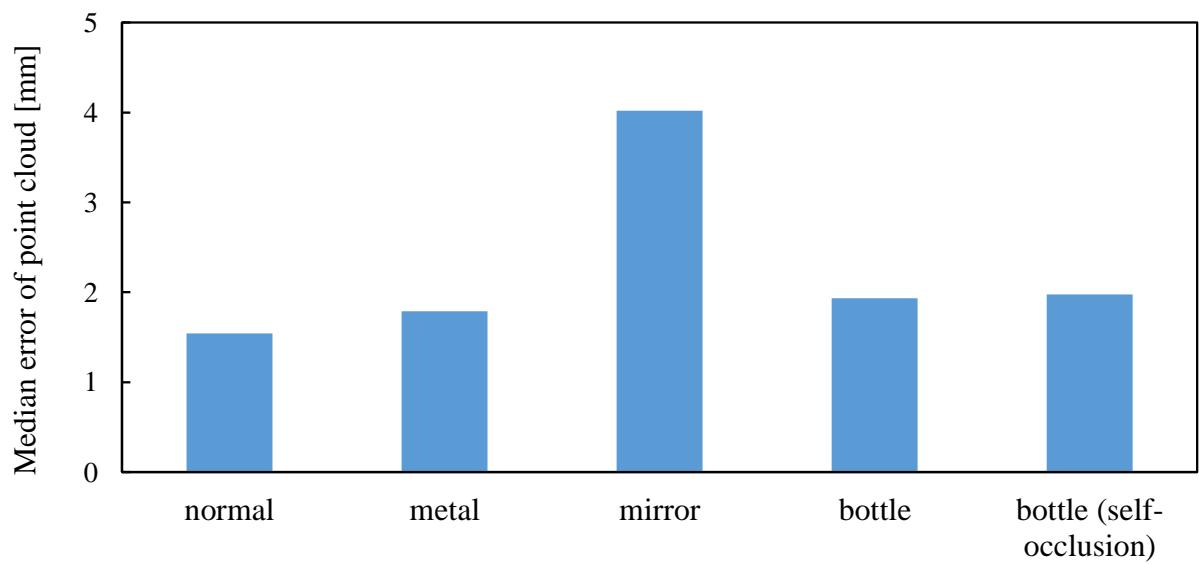


Fig. 4.21: Accuracy of fluorescent grid textures for difficult to recognize objects (N=100)



Fig. 4.22: Metal object under UV light source



Fig. 4.23: Metal object under visible light source

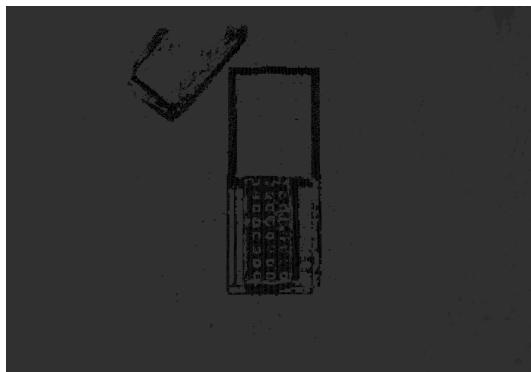


Fig. 4.24: Mirror under UV light source



Fig. 4.25: Mirror under visible light source

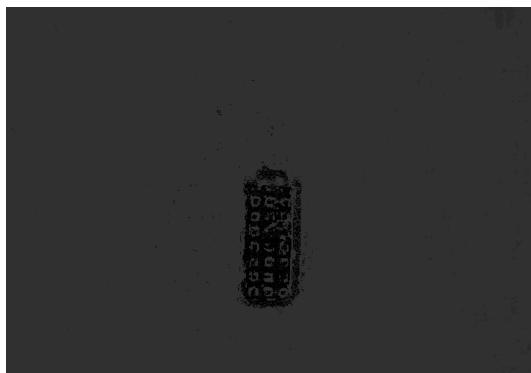


Fig. 4.26: Transparent bottle under UV light source

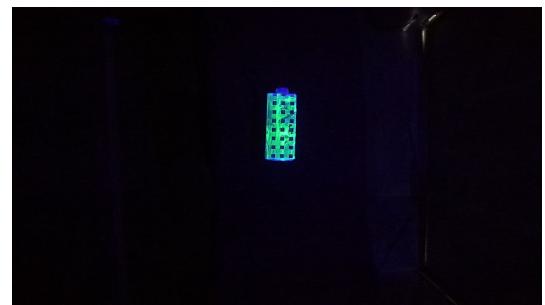


Fig. 4.27: Transparent bottle under visible light



Fig. 4.28: Transparent bottle with self-occlusion under UV light source

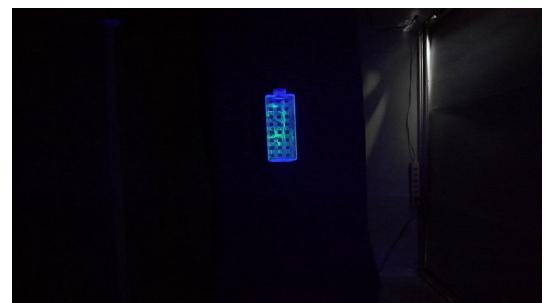


Fig. 4.29: Transparent bottle with self-occlusion under visible light source

第5章

結 言

蛍光塗料によるテクスチャを与えることにより、物体の三次元情報及びセマンティックセグメンテーションのための領域情報をもつた、通常光源で利用可能なデータセット生成を生成する自動アノテーション手法として蛍光テクスチャを提案した。

蛍光テクスチャは蛍光塗料の可視光では透明となり紫外線が与えられると可視光を発する性質 [15, 16] を利用しており、可視光と紫外線の光源を交互に切り替えながら蛍光領域に対して自動アノテーションを行っていく手法である。

提案した蛍光テクスチャは対象物体に与えるテクスチャを変えることで得られる特徴を変えることができるという拡張性がある。本研究ではこの蛍光テクスチャを使った例として、AR マーカのテクスチャを与えた蛍光マーカテクスチャとグリッド状のテクスチャを与えた蛍光グリッドテクスチャを提案した。これらのテクスチャは対応する AR マーカの認識器やステレオ視差、セグメンテーションネットワークなどの既存の認識手法によって三次元的な位置姿勢や画像上の物体領域をアノテーションすることができる。

本稿では 3.1 節において本研究の新規性と有用性について述べた。本研究の新規性と有用性について再度明記する。本研究は対象物体の画像上の情報を加えて、位置姿勢といった三次元情報についても自動的にアノテーションできる点に有用性がある。既存の三次元的な情報を扱うことのできるアプローチとしてはシミュレータを用いた手法があるが、本手法では現実のデータを直接扱うためにシミュレータアプローチと比較してリアルなデータセットを作れる利点がある。本研究には蛍光を用いて初めて三次元的な情報を扱うこととした点に新規性がある。また、蛍光を用いて三次元的な情報を扱えることを自動アノテーションに応用した点に新規性と有用性がある。本研究は蛍光塗料によって対象物体に計測可能なテクスチャを与えることで三次元のデータを扱えるように従来手法を拡張している。マーカを用いた自動アノテーションのアプローチにはマーカによって対象物体の一部が隠されるマーカオクルージョン問題があるが、本研究では可視光下で透明となる蛍

光塗料によってマーカを表現することでこの問題を解決している点に新規性と有用性がある。本研究ではシミュレータで扱うことの難しい不定形や、透明な物体のようなカメラによる認識の難しい透明物体に対しても適用可能である点に有用性がある。

今後の課題としては、本手法の紫外線環境の画像入力を通常光と紫外線を照射した画像の差分からセグメンテーションネットワークで蛍光領域を抽出した画像に置き換えることによって、本手法をより環境のコントロールを必要としない手法にしていくことが挙げられる(図5.1)。



Fig. 5.1: Diffrence in appearance of fluorescent paint

謝 辞

はじめに、本研究を行うにあたり全体を通してご指導、ご教授、議論などのご助力をいただきました本学ロボティクス学科の出村公成教授に深く感謝いたします。また、お忙しい中、本論文の査読をしていただいた藤木信彰准教授に感謝いたします。また、論文の執筆を陰ながらいつも支えてくれた Vim に敬意を表すると共に、作者の BramMoolenaar 様、日本 Vim 界隈におけるトップコントリビューター ShougoMatsu 様に深く感謝いたします。最後に、これまでの研究生活を暖かく見守り、支え続けて下さった家族に感謝します。

令和3年1月

参考文献

- [1] Amanda Berg, Joakim Johnander, Flavie Durand de Gevigney, Jorgen Ahlberg, and Michael Felsberg. Semi-automatic annotation of objects in visual-thermal video. In *IEEE International Conference on Computer Vision Workshops*, pp. 2242–2251, 2019.
- [2] Li Yi, Vladimir G Kim, Duygu Ceylan, I-Chao Shen, Mengyan Yan, Hao Su, Cewu Lu, Qixing Huang, Alla Sheffer, and Leonidas Guibas. A scalable active framework for region annotation in 3d shape collections. *ACM Transactions on Graphics*, Vol. 35, No. 6, pp. 1–12, 2016.
- [3] Tewodros A Biresaw, Tahir Nawaz, James Ferryman, and Anthony I Dell. Vitbat: Video tracking and behavior annotation tool. In *IEEE International Conference on Advanced Video and Signal Based Surveillance*, pp. 295–301, 2016.
- [4] Amanda Berg. Detection and tracking in thermal infrared imagery, 2016.
- [5] Lluis Castrejon, Kaustav Kundu, Raquel Urtasun, and Sanja Fidler. Annotating object instances with a polygon-rnn. In *IEEE conference on computer vision and pattern recognition*, pp. 5230–5238, 2017.
- [6] David Acuna, Huan Ling, Amlan Kar, and Sanja Fidler. Efficient interactive annotation of segmentation datasets with polygon-rnn++. In *IEEE conference on Computer Vision and Pattern Recognition*, pp. 859–868, 2018.
- [7] Takahashi Kuniyuki and Yonekura Kenta. Invisible marker: Automatic annotation of segmentation masks for object manipulation. *International Conference on Intelligent Robots and Systems*, 2020.
- [8] Takuya Kiyokawa, Keita Tomochika, Jun Takamatsu, and Tsukasa Ogasawara. Efficient collection and automatic annotation of real-world object images by taking advantage of post-

- diminished multiple visual markers. *Advanced Robotics*, Vol. 33, No. 24, pp. 1264–1280, 2019.
- [9] 佑斗内海, 健太郎和田, 慧岡田, 雅幸稲葉. 物体メッシュモデルを用いた学習データ自動生成に基づく透明物体の深度画像予測と家事支援ロボットへの応用. 人工知能学会全国大会論文集, Vol. JSAI2018, No. 0, pp. 3L202–3L202, 2018.
- [10] Takuya Kiyokawa, Keita Tomochika, Jun Takamatsu, and Tsukasa Ogasawara. Fully automated annotation with noise-masked visual markers for deep-learning-based object detection. *IEEE Robotics and Automation Letters*, Vol. 4, No. 2, pp. 1972–1977, Feb 2019.
- [11] 真也岡田, 隆一上田, 靖男林原. 引き紐を利用した視覚と行動の end-to-end 学習による移動ロボットの人追従行動の生成. pp. 1082–1086. 第 20 回計測自動制御学会システムインテグレーション部門講演会, 2019.
- [12] Konstantinos Bousmalis, Alex Irpan, Paul Wohlhart, Yunfei Bai, Matthew Kelcey, Mrinal Kalakrishnan, Laura Downs, Julian Ibarz, Peter Pastor, Kurt Konolige, et al. Using simulation and domain adaptation to improve efficiency of deep robotic grasping. In *IEEE international conference on robotics and automation*, pp. 4243–4250, 2018.
- [13] Huan Luo, Cheng Wang, and Jonathan Li. Auto-annotation of 3d objects via imagenet. In *AAAI Conference on Artificial Intelligence*, Vol. 31, 2017.
- [14] Simon Baker, Daniel Scharstein, JP Lewis, Stefan Roth, Michael J Black, and Richard Szeliski. A database and evaluation methodology for optical flow. *International journal of computer vision*, Vol. 92, No. 1, pp. 1–31, 2011.
- [15] Bernard Valeur and Mario N Berberan-Santos. A brief history of fluorescence and phosphorescence before the emergence of quantum theory. *Journal of Chemical Education*, Vol. 88, No. 6, pp. 731–738, 2011.
- [16] Tali Treibitz, Zak Murez, B. Greg Mitchell, and David Kriegman. Shape from fluorescence. In Andrew Fitzgibbon, Svetlana Lazebnik, Pietro Perona, Yoichi Sato, and Cordelia Schmid, editors, *Computer Vision – ECCV*, pp. 292–306. Springer Berlin Heidelberg, 2012.
- [17] Sergio Garrido-Jurado, Rafael Muñoz-Salinas, Francisco José Madrid-Cuevas, and Manuel Jesús Marín-Jiménez. Automatic generation and detection of highly reliable fiducial markers under occlusion. *Pattern Recognition*, Vol. 47, No. 6, pp. 2280–2292, 2014.

- [18] Mark Fiala. Artag, a fiducial marker system using digital techniques. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, Vol. 2, pp. 590–596, 2005.
- [19] Hideaki Uchiyama and Hideo Saito. Random dot markers. In *IEEE Virtual Reality Conference*, pp. 35–38, 2011.
- [20] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*, pp. 234–241, 2015.
- [21] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *IEEE conference on computer vision and pattern recognition*, pp. 2117–2125, 2017.
- [22] Abhishek Chaurasia and Eugenio Culurciello. Linknet: Exploiting encoder representations for efficient semantic segmentation. In *IEEE Visual Communications and Image Processing*, pp. 1–4, 2017.
- [23] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [24] Xiaoya Li, Xiaofei Sun, Yuxian Meng, Junjun Liang, Fei Wu, and Jiwei Li. Dice loss for data-imbalanced nlp tasks. *arXiv preprint arXiv:1911.02855*, 2019.

本研究に関する学術発表論文

岡野昭伍, 出村公成, 萤光テクスチャによる深層学習のためデータセット生成, 第38回日本ロボット学会学術講演会, 3D1-05, (2020)